




Russian -> Polish ASR Tongue Twister Studio

Anna Przyłucka, Milana Ronchyk

Informatyka Medyczna, rok II
28.05.2026

Contents



01 :
Pomysł

02 Dane

03 Tryby pracy

04 Demo

05 Pomiar

06 Wyniki & wnioski

An abstract, organic shape in shades of pink and red, resembling a splash or a soft, glowing form, set against a solid black background. The shape has a gradient from a deep magenta on the left to a bright, almost white-pink on the right, with a darker red area in the center-right. The word "POMYSŁ" is centered within this shape in a white, serif font.

POMYSŁ

GŁUPIE POMYSŁY SĄ NAJLEPSZE ...

Ania & Milana

When u and ur bff realize ur both evil



An abstract, organic shape in shades of pink and red, resembling a splash or a soft, glowing form, set against a solid black background. The shape has a gradient, with darker pink on the left and brighter red on the right. The word "DANE" is centered within the shape in a white, serif font.

DANE

TONGUE TWISTERS ... BECAUSE WHY NOT



mxxmikk, yesterday | 1 author (mxxmikk)

Karl od Klary ukradł korale, a Klara od Karla ukradła klarnet.

You, 3 days ago | 1 author (You)

Карл у Клary украл кораллы, а Клара у Карла укpала кларнет.

mxxmikk, yesterday | 1 author (mxxmikk)

Zjadł Sława słone sadło, lecz sadła Sławie mało.

mxxmikk, yesterday | 1 author (mxxmikk)

Съел Слава солeно сало, да сала Славе мало.

mxxmikk, yesterday | 1 author (mxxmikk)

Do fabryki szyszkosuszarniczej poszukiwany jest szyszkosuszacz do pracy na aparacie szyszkosuszarniczym. Szyszkosuszacz powinien mieć doświadczenie szyszkosuszenia na aparacie szyszkosuszarniczym z wykorzystaniem szyszkosuszarniczej technologii jakościowego szyszkosuszenia. On także powinien odróżniać aparat szyszkosuszenia od nieszyszkosuszenia, naprawiać aparat szyszkosuszarniczy, odróżniać szyszki nadające się do szyszkosuszenia od nienadających się do szyszkosuszenia, odróżniać szyszki niedoszyszkosuszone od przeszyszkosuszonych, za każdą niedoszyszkosuszoną lub przeszyszkosuszoną szyszkę szyszkosuszacz otrzyma szyszkosusząrką po głowie.!

mxxmikk

mxxmikk, yesterday | 1 author (mxxmikk)

Na шишкосушилную фабрику требуется шишкосушитель для работы на шишкосушительном аппарате. Шишкосушитель должен иметь опыт шишкосушения на шишкосушительном аппарате с использованием шишкосушительной технологии качественного шишкосушения. Он также должен отличать аппарат шишкосушения от нешишкосушения, ремонтировать шишкосушительный аппарат, отличать шишки, пригодные для шишкосушения, от негодных для шишкосушения, отличать шишки недошишкосушенные от перешишкосушенных, за каждую недошишкосушенную или перешишкосушенную шишку шишкосушитель получит шишкосушилкой по голове.!

mxxmikk, yesterday • fix: changed transcription of tongue twisters. ...

TROCHEŁ LICZB

Format & Język

WAV / Rosyjski

60


Nagrań

12

Osób

5

Średnio na osobę



An abstract, organic shape in shades of pink and red, resembling a splash or a soft, glowing form, set against a solid black background. The shape has a gradient from a deep magenta on the left to a bright, almost white-pink on the right, with a darker red area in the center-right. The text "TRYBY PRACY" is centered within this shape in a white, serif font.

TRYBY PRACY

An abstract, organic shape in shades of pink and red, resembling a splash or a soft, glowing form, set against a solid black background. The shape has a gradient, with darker pink on the left and a brighter, more saturated red on the right side.

I. MODEL COMPARISON

MODEL COMPARISON

Control Panel

Upload a Russian tongue twister audio to generate a transcript and a Polish translation.

Select App Mode:

- Analysis
- Model Comparison

Run benchmark on dataset

This mode shows charts from your benchmark runs.

Model ranking

BEST OVERALL MODEL

whisper:small

Composite score: 81.1

WER: 0.686

Latency: 91.50 s

Token F1: 0.398

Rank	Model	Composite score	WER	CER	Token F1	Exact match	Latency [s]
1	whisper:small	81.13	0.686	0.434	0.398	0.086	91.50
2	hfjonatasgrosman/wav2vec2-large-xlsr-53-russian	74.63	0.865	0.468	0.439	0.000	3.71
3	whisper:base	54.14	0.858	0.572	0.222	0.000	15.02
4	whisper:tiny	13.87	1.181	0.939	0.180	0.000	12.79

Chart gallery


Click the arrow on a card to expand an interactive chart, then use fullscreen in the chart toolbar for a larger view.

[01] Quality metrics overview

WER, CER, Token F1 and exact match side by side.

Model quality metrics (WER/CER lower is better)


- CER
- Token F1
- Exact match



[02] Quality vs speed trade-off

Latency and WER with bubble size based on memory usage.

Quality vs speed trade-off (bubble size = RAM)



RUSSIAN TO POLISH ASR

Tongue Twister Studio

Model Comparison

Comparative metrics and charts from your dataset benchmark runs.

Latest run: 20260527_203830 | Path: src\ui\model_comparison\results\run_20260527_203830

Leaderboard

	samples_count	wer_mean	cer_mean	token_precision_mean	token_recall_mean	token_f1_mean	exact_n
	58	0.6859	0.4339	0.4479	0.3856	0.398	
	58	0.8584	0.5725	0.2523	0.2126	0.2222	
wav2vec2-large-xlsr-53-russian	58	0.8646	0.4677	0.4503	0.4412	0.4393	
	58	1.1814	0.9389	0.191	0.1767	0.1799	

Interactive comparison charts

Best WER

0.686

↑ whisper

Best Token F1

0.439



↑ hfjonatasgrosman/wav...

Lowest Latency

3.71s

↑ hfjonatasgrosman/wav...

Saved benchmark image charts



An abstract, organic shape in shades of pink and red, resembling a splash or a soft, glowing form, set against a solid black background. The shape has a textured, slightly grainy appearance. The text "II. ANALYSIS" is centered within this shape in a white, serif font.

II. ANALYSIS

ANALYSIS

Control Panel

Upload a Russian tongue twister audio to generate a transcript and a Polish translation.

Select App Mode:

- ☒ Analysis
☐ Model Comparison

Upload audio

 Upload

200MB per file • WAV

Run analysis

RUSSIAN TO POLISH ASR

Tongue Twister Studio

Processing Flow



Upload

Audio selected

1



ASR

Speech decoding

2



Words

Word sequence

3



Transcript

Sentence assembly

4



PL

Polish output

5

Original Tongue Twister

Source: No file selected

Title: Shla Sasha po shosse

RUSSIAN ORIGINAL

Шла Саша по шоссе и сосала сушку.

POLISH TRANSLATION

Szła Sasza po szosie i ssala suszkę.

Audio and Waveform

Upload an audio file or load the demo sample.

Recognition and Translation

Recognized Russian words

Waiting for analysis result.

Transcript

Transcript (ASR)

Polish output

Polish translation

An abstract, organic shape in shades of pink and red, resembling a liquid splash or a soft, glowing form. The shape is centered on a solid black background. The color transitions from a deep magenta on the left to a bright, almost white-pink on the right, with a vibrant red core in the center. The word "DEMO" is written in a white, serif font across the middle of the shape.

DEMO

бабуля

last seen 7 hours ago




00:00.4

Cancel



Emoji Stickers GIFs



An abstract, organic shape in shades of pink and red, resembling a splash or a soft, glowing form, set against a solid black background. The shape has a gradient from a deep magenta on the left to a bright, almost white-pink on the right, with a darker red area in the center-right. The word "POMIARY" is centered within this shape in a white, serif font.

POMIARY

METRYKI DO OCENY MODELI

Dokładność Tekstu

WER - Word Error Rate

CER - Character Error Rate

Zasada: im niższy wynik, tym lepiej.

Precyzja i Dopasowanie

Token F1 - kompromis precision/recall


Exact Match - idealne transkrypcje

Wydajność i Zasoby (Inference)

Latency - opóźnienie, czas odpowiedzi modelu na zapytanie.

RTF (Real Time Factor) - stosunek czasu procesowania do długości audio.

Peak memory - maksymalne obciążenie pamięci RAM/VRAM.



MODELE

ASR

whisper:tiny

najslabsza jakość
w tym runie

ASR

whisper:base

średnia jakość;
szybszy niż small

ASR

whisper:small

najlepszy overall;
min. WER/CER

ASR

**wav2vec2
XLSR RU**

fallback tłumaczenia

facebook/nllb-200-distilled-600M

RU → PL, gdy brakuje dopasowania
z referencji



An abstract, organic shape in shades of pink and red, resembling a splash or a soft, glowing form, set against a solid black background. The shape has a gradient, with darker pink on the left and brighter red on the right, and a soft, glowing edge.



WYNIKI & WNIOSKI

WYNIKI

Dane: run 20260527_203830 – 58 próbek

TABLE_RESULTS_SUMMARY


WER/ CER	whisper:small	WER 0.686 CER 0.434
Token F1	wav2vec2 XLSR RU	Token F1: 0.439
Exact Match	whisper:small	Exact Match: 8.62%
Latency/RTF	wav2vec2 XLSR RU	3.71 s RTF: 0.316



RANKING:




Whisper-tiny



Najslabszy wynik jakościowy. Najmniejszy model z rodziny Whisper, ale w benchmarku uzyskał najwyższy poziom błędów WER i CER oraz najniższy Token F1. Może być użyteczny tylko tam, gdzie liczy się prostota modelu, a nie precyzja.



Whisper-small



Najlepszy model ogólnie: osiąga najniższy WER i CER oraz jako jedyny uzyskał wynik Exact Match. Daje najlepszą jakość transkrypcji, ale kosztem bardzo wysokiej latencji.



Whisper-base



Stabilny, ale bez przewagi. Oferuje lepszą jakość niż Whisper-tiny, jednak przegrywa z Whisper-small pod względem dokładności i z Wav2Vec2 pod względem szybkości. To model pośredni, ale nie najlepszy w żadnej głównej kategorii.



Wav2Vec2



Najlepszy pod względem szybkości. Model działa zdecydowanie najszybciej i ma najwyższy Token F1. Jest dobry do szybkiego przetwarzania nagrań, ale ma wyższy WER niż Whisper-small i nie uzyskał Exact Match.

WNIOSKI



Jakość

- whisper:small ma najniższy WER/CER: 0.686 / 0.434
- jako jedyny uzyskał Exact Match: 8.62%
- wav2vec2 ma najlepszy Token F1: 0.439
- base i tiny wypadają słabiej jakościowo

Szybkość

- wav2vec2 jest najszybszy: 3.71 s, RTF 0.316
- whisper:small jest najwolniejszy: 91.50 s
- whisper:tiny nie daje dobrego kompromisu
- wybór zależy od priorytetu: jakość lub czas

quality work





THE END!

DZIĘKUJEMY ZA UWAGĘ!!!